

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ИМ. Н.Э. БАУМАНА

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ № 1
ПО КУРСУ: "АНАЛИЗ АЛГОРИТМОВ"
Тема: "Алгоритм Левенштейна"

Студент: Орехова Екатерина ИУ7-51

27 февраля 2018 г.

Содержание

1	Постановка задачи	2
2	Описание алгоритма	2
2.1	Рекурсивный алгоритм	3
2.2	Матричный алгоритм	3
2.3	Модифицированный алгоритм	3
3	Реализация	4
4	Тесты	8
5	Сравнение	8
6	Заключение	9

1 Постановка задачи

В ходе выполнения лабораторной работы необходимо изучить алгоритм Левенштейна. Реализовать базовый алгоритм Левенштейна, рекурсивный алгоритм Левенштейна, модифицированный алгоритм Левенштейна. Сравнить эти алгоритмы.

2 Описание алгоритма

Расстояние Левенштейна (также редакционное расстояние или дистанция редактирования) между двумя строками в теории информации и компьютерной лингвистике это минимальное количество операций вставки одного символа, удаления одного символа и замены одного символа на другой, необходимых для превращения одной строки в другую. Допустимы редакторские операции:

- D (delete) — удалить,
- I (insert) — вставить,
- R (replace) — заменить,
- M (match) — совпадение.

Модификацией данного алгоритма является алгоритм Дамерау — Левенштейна, суть которого заключается в добавлении ещё одной редакторской операции : C(change) – перестановки двух соседних символов. Пусть $w(x)$ – цена операции x , тогда:

- $w(D) = 1$
- $w(I) = 1$
- $w(R) = 1$
- $w(M) = 0$
- $w(C) = 1$

2.1 Рекурсивный алгоритм

Пусть S_1 и S_2 – две строки (длиной M и N) соответственно, тогда редакционное расстояние можно подсчитать по следующей рекуррентной формуле $d(S_1, S_2) = D(M, N)$ где

$$D[i][j] = \begin{cases} 0, & \text{если } i = 0, j = 0; \\ i, & \text{если } j = 0, i > 0; \\ j, & \text{если } i = 0, j > 0; \\ \min\{D(i, j-1) + 1, D(i-1, j) + 1, D(i-1, j-1) + m(S_1[i], S_2[j])\}, & \text{если } i > 0, j > 0. \end{cases}$$

где $m(a, b)$ равна нулю, если $a=b$ и единице в противном случае;
 $\min(a, b, c)$ возвращает наименьший из аргументов.

2.2 Матричный алгоритм

Матричный алгоритм можно описать с помощью следующей иллюстрации

X_z	X_y
X_v	$D_{i,j}$


$$D_{ij} = \min (X_v + 1, X_y + 1, X_z + C_{\text{замены}})$$

$$C_{\text{замены}} = \begin{cases} 1, & \text{если } S_1[i] \neq S_2[j] \\ 0, & \text{иначе} \end{cases}$$

Рис. 1: Матричный алгоритм

2.3 Модифицированный алгоритм

Модифицированный алгоритм добавляет ещё одну операцию: перестановка двух соседних символов (или как по другому её называют - транспозиция) Модификацию матричного алгоритма можно представить следующей иллюстрацией



$$D_{ij} = \min(X_v + 1, X_y + 1, X_z + C_{\text{замены}}, X_t + C_{\text{транспозиции}})$$

$$C_{\text{замены}} = \begin{cases} 1, & \text{если } S_1[i] \neq S_2[j] \\ 0, & \text{иначе} \end{cases}$$

$$C_{\text{транспозиции}} = \begin{cases} 1, & \text{если } S_1[i] = S_2[j-1] \text{ и } S_1[i-1] = S_2[j] \\ \infty, & \text{иначе} \end{cases}$$

Рис. 2: Модифицированный алгоритм

3 Реализация

Листинг 1: main

```
static void Main(string[] args)
{
    string word1 = Console.ReadLine();
    string word2 = Console.ReadLine();
    int len1, len2;
    len1 = word1.Length;
    len2 = word2.Length;
    // ooooo \ y\ 2\ 3

    functions.max = Math.Max(len1, len2) + 1;
    int d = functions.distance_rec(word1, word2, len1 - 1, len2 - 1);
    int d1 = functions.distance_matr(word1, word2, len1, len2);
    int dmod = functions.distance_modify(word1, word2, len1, len2);
}
```

```

        Console.WriteLine("Levenshtein distance recursion " +
            d.ToString() + "\n");
        Console.WriteLine("Levenshtein distance matrix " +
            d1.ToString() + "\n");
        Console.WriteLine("Levenshtein distance matrix modify " +
            + dmod.ToString() + "\n");
        Console.Read();
    }

```

Листинг 2: Рекурсивный алгоритм

```

public static int distance_rec(string word1, string
    word2, int len1, int len2)
{
    if (len1 == -1)
    {
        if (len2 == -1)
            return 0;
        return len2+1;
    }
    if (len2 == -1)
        return len1+1;
    int d = 0;
    d = Math.Min(distance_rec(word1, word2, len1, len2 -
        1) + 1, Math.Min(
        distance_rec(word1, word2, len1 - 1, len2) + 1,
        distance_rec(word1, word2, len1 - 1, len2 - 1) +
            m(word1[len1], word2[len2])));
    return d;
}

```

Функция сравнения 2-х символов

Листинг 3: m

```

public static int m(char a, char b)
{
    if (a == b)
        return 0;
    return 1;
}

```

Листинг 4: Матричный алгоритм

```

public static int distance_matr(string word1, string
word2, int len1, int len2)
{
    int d = 0;
    int[,] matr = new int[len1+1, len2+1];

    //заполнение нулевой строки
    for (int i = 0; i <= len1; i++)
        matr[i, 0] = i;

    //заполнение нулевого столбца
    for (int i = 0; i <= len2; i++)
        matr[0, i] = i;

    //заполнение матрицы
    for (int j = 1; j <= len2; j++) //по столбцам
        for (int i = 1; i <= len1; i++) //по строкам
            matr[i, j] =
                Math.Min(Math.Min(matr[i-1, j]+1, matr[i, j-1]+1),
                    m(word1[i-1], word2[j-1])+matr[i-1, j-1]);

    d = matr[len1, len2];
    return d;
}

```

Листинг 5: Модифицированный алгоритм

```

public static int distance_modify(string word1, string
word2, int len1, int len2)
{
    int d = 0;
    int[,] matr = new int[len1 + 1, len2 + 1];
    max = Math.Max(len1, len2) + 1;

    //заполнение нулевой строки
    for (int i = 0; i <= len1; i++)
        matr[i, 0] = i;

    //заполнение нулевого столбца
    for (int i = 0; i <= len2; i++)
        matr[0, i] = i;

    //заполнение матрицы
    for (int j = 1; j <= len2; j++) //по столбцам

```

```

    for (int i = 1; i <= len1; i++) //по строкам
    {
        if ((j>=2)&&(i>=2))
            matr[i, j] = Math.Min(Math.Min(matr[i -
                1, j] + 1, matr[i, j - 1] + 1),
                Math.Min(m(word1[i - 1], word2[j - 1]) +
                    matr[i - 1, j - 1],
                    transpoze(word1,word2,i-1,j-1)
                        +matr[i-2,j-2])));
        else
            matr[i, j] = Math.Min(Math.Min(matr[i -
                1, j] + 1, matr[i, j - 1] + 1),
                m(word1[i - 1], word2[j - 1]) + matr[i -
                    1, j - 1]);

    }
    d = matr[len1, len2];
    return d;
}

```

Листинг 6: Коэффициент транспозиции

```

private static int transpoze(string word1, string word2,
    int i, int j)
{
    if ((word1[i] == word2[j-1])&&(word1[i-1]==word2[j]))
        return 1;
    return max;
}

```

4 Тесты

Таблица 1: Пример работы алгоритма

Первая строка	Вторая строка	Базовый алгоритм	Модифицированный алгоритм	Тест
Word	word	1	1	Замена
word	world	1	1	Добавление
word	smwordly	4	4	Добавление в начале и в конце
mother	other	1	1	Удаление
	word	4	4	Пустая строка
word		4	4	Пустая строка
word	word	0	0	Одинаковые строки
word	wrod	2	1	Перестановка
word	drow	4	3	Перестановка и замена

5 Сравнение

Таблица 2: Временной тест

Тест	Рекурсивный	Матричный	Модифицированный
Word - word	43	4	5
word - world	89	6	6
word - smwordly	475	8	10
mother - other	434	20	7
-word	0	1	1
word-	0	0	1
word - word	33	3	4
word - wrod	44	5	5
word - drow	28	2	3

Из представленной выше таблицы видно, что рекурсивный алгоритм в среднем работает медленнее.

6 Заключение

В ходе выполнения лабораторной работы был изучен алгоритм Левенштейна. Реализованы базовый алгоритм Левенштейна, рекурсивный алгоритм Левенштейна, модифицированный алгоритм Левенштейна. Выполнено сравнение реализованных алгоритмов.